Hands-On

Hands-On ini digunakan pada kegiatan Microcredential Associate Data Scientist 2021

Tugas Mandiri Pertemuan 10

Pertemuan 10 (sepuluh) pada Microcredential Associate Data Scientist 2021 menyampaikan materi mengenai Membangun Model (Dasar Regresi dan Regresi Linier). silakan Anda kerjakan Latihan 1 s/d 20. Output yang anda lihat merupakan panduan yang dapat Anda ikuti dalam penulisan code :)

Latihan (1)

Melakukan import library yang dibutuhkan

In [34]:
```
# import library pandas
import pandas as pd

# Import library numpy
import numpy as np

# Import library matplotlib dan seaborn untuk visualisasi
import matplotlib.pyplot as plt
import seaborn as sns

# Import Module LinearRegression digunakan untuk memanggil algoritma Linear Regression.
from sklearn.linear_model import LinearRegression

# import Module train_test_split digunakan untuk membagi data kita menjadi training dan testing set.
from sklearn.model_selection import train_test_split

# import modul mean_absolute_error dari library sklearn
from sklearn.metrics import mean_absolute_error

#import math agar program dapat menggunakan semua fungsi yang ada pada modul math.(ex:sqrt)
import math

# me-non aktifkan peringatan pada python
import warnings
warnings.filterwarnings('ignore')
```

Load Dataset

In [35]:
```
#Panggil file (load file bernama CarPrice_Assignment.csv) dan simpan dalam dataframe Lalu tampilkan 10 baris aw
data = pd.read_csv('CarPrice_Assignment.csv')
dataset = pd.DataFrame(data)
dataset.head(10)
```

Out[35]:

	car_ID	symboling	CarName	fueltype	aspiration	doornumber	carbody	drivewheel	enginelocation	wheelbase	...	enginesize	fuelsy
0	1	3	alfa-romero giulia	gas	std	two	convertible	rwd	front	88.6	...	130	
1	2	3	alfa-romero stelvio	gas	std	two	convertible	rwd	front	88.6	...	130	
2	3	1	alfa-romero Quadrifoglio	gas	std	two	hatchback	rwd	front	94.5	...	152	
3	4	2	audi 100 ls	gas	std	four	sedan	fwd	front	99.8	...	109	
4	5	2	audi 100ls	gas	std	four	sedan	4wd	front	99.4	...	136	
5	6	2	audi fox	gas	std	two	sedan	fwd	front	99.8	...	136	
6	7	1	audi 100ls	gas	std	four	sedan	fwd	front	105.8	...	136	
7	8	1	audi 5000	gas	std	four	wagon	fwd	front	105.8	...	136	
8	9	1	audi 4000	gas	turbo	four	sedan	fwd	front	105.8	...	131	
9	10	0	audi 5000s (diesel)	gas	turbo	two	hatchback	4wd	front	99.5	...	131	

10 rows × 26 columns

Latihan (2)

Review Dataset

In [36]:
```
# melihat jumlah baris dan jumlah kolom (bentuk data) pada data df dengan fungsi .shape
dataset.shape
```

Out[36]:
```
(205, 26)
```

Data kita mempunyai 26 kolom dengan 205 baris.

In [37]:
```
# Melihat Informasi lebih detail mengenai struktur DataFrame dapat dilihat menggunakan fungsi info()
dataset.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 205 entries, 0 to 204
Data columns (total 26 columns):
 #   Column            Non-Null Count  Dtype  
---  ------            --------------  -----  
 0   car_ID            205 non-null    int64  
 1   symboling         205 non-null    int64  
 2   CarName           205 non-null    object 
 3   fueltype          205 non-null    object 
 4   aspiration        205 non-null    object 
 5   doornumber        205 non-null    object 
 6   carbody           205 non-null    object 
 7   drivewheel        205 non-null    object 
 8   enginelocation    205 non-null    object 
 9   wheelbase         205 non-null    float64
 10  carlength         205 non-null    float64
 11  carwidth          205 non-null    float64
 12  carheight         205 non-null    float64
 13  curbweight        205 non-null    int64  
 14  enginetype        205 non-null    object 
 15  cylindernumber    205 non-null    object 
 16  enginesize        205 non-null    int64  
 17  fuelsystem        205 non-null    object 
 18  boreratio         205 non-null    float64
 19  stroke            205 non-null    float64
 20  compressionratio  205 non-null    float64
 21  horsepower        205 non-null    int64  
 22  peakrpm           205 non-null    int64  
 23  citympg           205 non-null    int64  
 24  highwaympg        205 non-null    int64  
 25  price             205 non-null    float64
dtypes: float64(8), int64(8), object(10)
memory usage: 41.8+ KB
```

In [72]:
```
# melihat statistik data untuk data numeric seperti count, mean, standard deviation, maximum, mininum, dan qua
dataset.describe()
```

Out[72]:

	car_ID	symboling	wheelbase	carlength	carwidth	carheight	curbweight	enginesize	boreratio	stroke	compressionrat
count	205.000000	205.000000	205.000000	205.000000	205.000000	205.000000	205.000000	205.000000	205.000000	205.000000	205.0000
mean	103.000000	0.834146	98.756585	174.049268	65.907805	53.724878	2555.565854	126.907317	3.329756	3.255415	10.1425
std	59.322565	1.245307	6.021776	12.337289	2.145204	2.443522	520.680204	41.642693	0.270844	0.313597	3.9720
min	1.000000	-2.000000	86.600000	141.100000	60.300000	47.800000	1488.000000	61.000000	2.540000	2.070000	7.0000
25%	52.000000	0.000000	94.500000	166.300000	64.100000	52.000000	2145.000000	97.000000	3.150000	3.110000	8.6000
50%	103.000000	1.000000	97.000000	173.200000	65.500000	54.100000	2414.000000	120.000000	3.310000	3.290000	9.0000
75%	154.000000	2.000000	102.400000	183.100000	66.900000	55.500000	2935.000000	141.000000	3.580000	3.410000	9.4000
max	205.000000	3.000000	120.900000	208.100000	72.300000	59.800000	4066.000000	326.000000	3.940000	4.170000	23.0000

In [39]:
```
# cek nilai yang hilang / missing values di dalam data
dataset.isna().sum()
```

Out[39]:
```
car_ID              0
symboling           0
CarName             0
fueltype            0
aspiration          0
doornumber          0
carbody             0
drivewheel          0
enginelocation      0
wheelbase           0
carlength           0
carwidth            0
carheight           0
curbweight          0
enginetype          0
cylindernumber      0
enginesize          0
fuelsystem          0
boreratio           0
stroke              0
compressionratio    0
horsepower          0
peakrpm             0
citympg             0
highwaympg          0
price               0
dtype: int64
```

Ternyata data kita tidak ada missing values.

Simple linear regression atau regresi linear sederhana merupakan jenis regresi yang paling sederhana karena hanya melibatkan satu variabel bebas atau variabel independen X.

Visualisasi data untuk pemilihan fitur / variabel independen X

---

1. Variabel y atau variabel dependent adalah 'price'
2. Lakukan Visualisasi dalam penerapannya agar dapat terlihat jelas / mempermudah dalam membaca data tsb
3. Untuk dapat menentukan variabel X yaitu dapat melihat korelasi antar variabel dengan variabel y / kolom 'price'

Latihan (3)

untuk dapat menentukan lebih detail / akurat dalam pemilihan fitur dapat dilihat dari hubungan korelasi nya dengan function corr()

In [40]:
```
dataset.corr()
```

Out[40]:

	car_ID	symboling	wheelbase	carlength	carwidth	carheight	curbweight	enginesize	boreratio	stroke	compressionr
car_ID	1.000000	-0.151621	0.129729	0.170636	0.052387	0.255960	0.071962	-0.033930	0.260064	-0.160824	0.150
symboling	-0.151621	1.000000	-0.531954	-0.357612	-0.232919	-0.541038	-0.227691	-0.105790	-0.130051	-0.008735	-0.178
wheelbase	0.129729	-0.531954	1.000000	0.874587	0.795144	0.589435	0.776386	0.569329	0.488750	0.160959	0.249
carlength	0.170636	-0.357612	0.874587	1.000000	0.841118	0.491029	0.877728	0.683360	0.606454	0.129533	0.158
carwidth	0.052387	-0.232919	0.795144	0.841118	1.000000	0.279210	0.867032	0.735433	0.559150	0.182942	0.181
carheight	0.255960	-0.541038	0.589435	0.491029	0.279210	1.000000	0.295572	0.067149	0.171071	-0.055307	0.261
curbweight	0.071962	-0.227691	0.776386	0.877728	0.867032	0.295572	1.000000	0.850594	0.648480	0.168790	0.151
enginesize	-0.033930	-0.105790	0.569329	0.683360	0.735433	0.067149	0.850594	1.000000	0.583774	0.203129	0.028
boreratio	0.260064	-0.130051	0.488750	0.606454	0.559150	0.171071	0.648480	0.583774	1.000000	-0.055909	0.005
stroke	-0.160824	-0.008735	0.160959	0.129533	0.182942	-0.055307	0.168790	0.203129	-0.055909	1.000000	0.186
compressionratio	0.150276	-0.178515	0.249786	0.158414	0.181129	0.261214	0.151362	0.028971	0.005197	0.186110	1.000
horsepower	-0.015006	0.070873	0.353294	0.552623	0.640732	-0.108802	0.750739	0.809769	0.573677	0.080940	-0.204
peakrpm	-0.203789	0.273606	-0.360469	-0.287242	-0.220012	-0.320411	-0.266243	-0.244660	-0.254976	-0.067964	-0.435
citympg	0.015940	-0.035823	-0.470414	-0.670909	-0.642704	-0.048640	-0.757414	-0.653658	-0.584532	-0.042145	0.324
highwaympg	0.011255	0.034606	-0.544082	-0.704662	-0.677218	-0.107358	-0.797465	-0.677470	-0.587012	-0.043931	0.265
price	-0.109093	-0.079978	0.577816	0.682920	0.759325	0.119336	0.835305	0.874145	0.553173	0.079443	0.067

tampaknya enginesize, boreratio, horsepower, wheelbase memiliki korelasi yang signifikan dengan harga/price.

Latihan (4)

Buat Visualisasi scater plot dari kolom:

'enginesize', 'boreratio', 'stroke','compressionratio', 'horsepower', 'peakrpm', 'wheelbase', 'citympg', 'highwaympg'

In [71]:
```
def pp(x,y,z):
    sns.pairplot(dataset, x_vars=[x, y, z], y_vars='price', size=4, aspect=1, diag_kind=None)
    plt.show()


pp('enginesize', 'boreratio', 'stroke')
pp('compressionratio', 'horsepower', 'peakrpm')
pp('wheelbase', 'citympg', 'highwaympg')
```

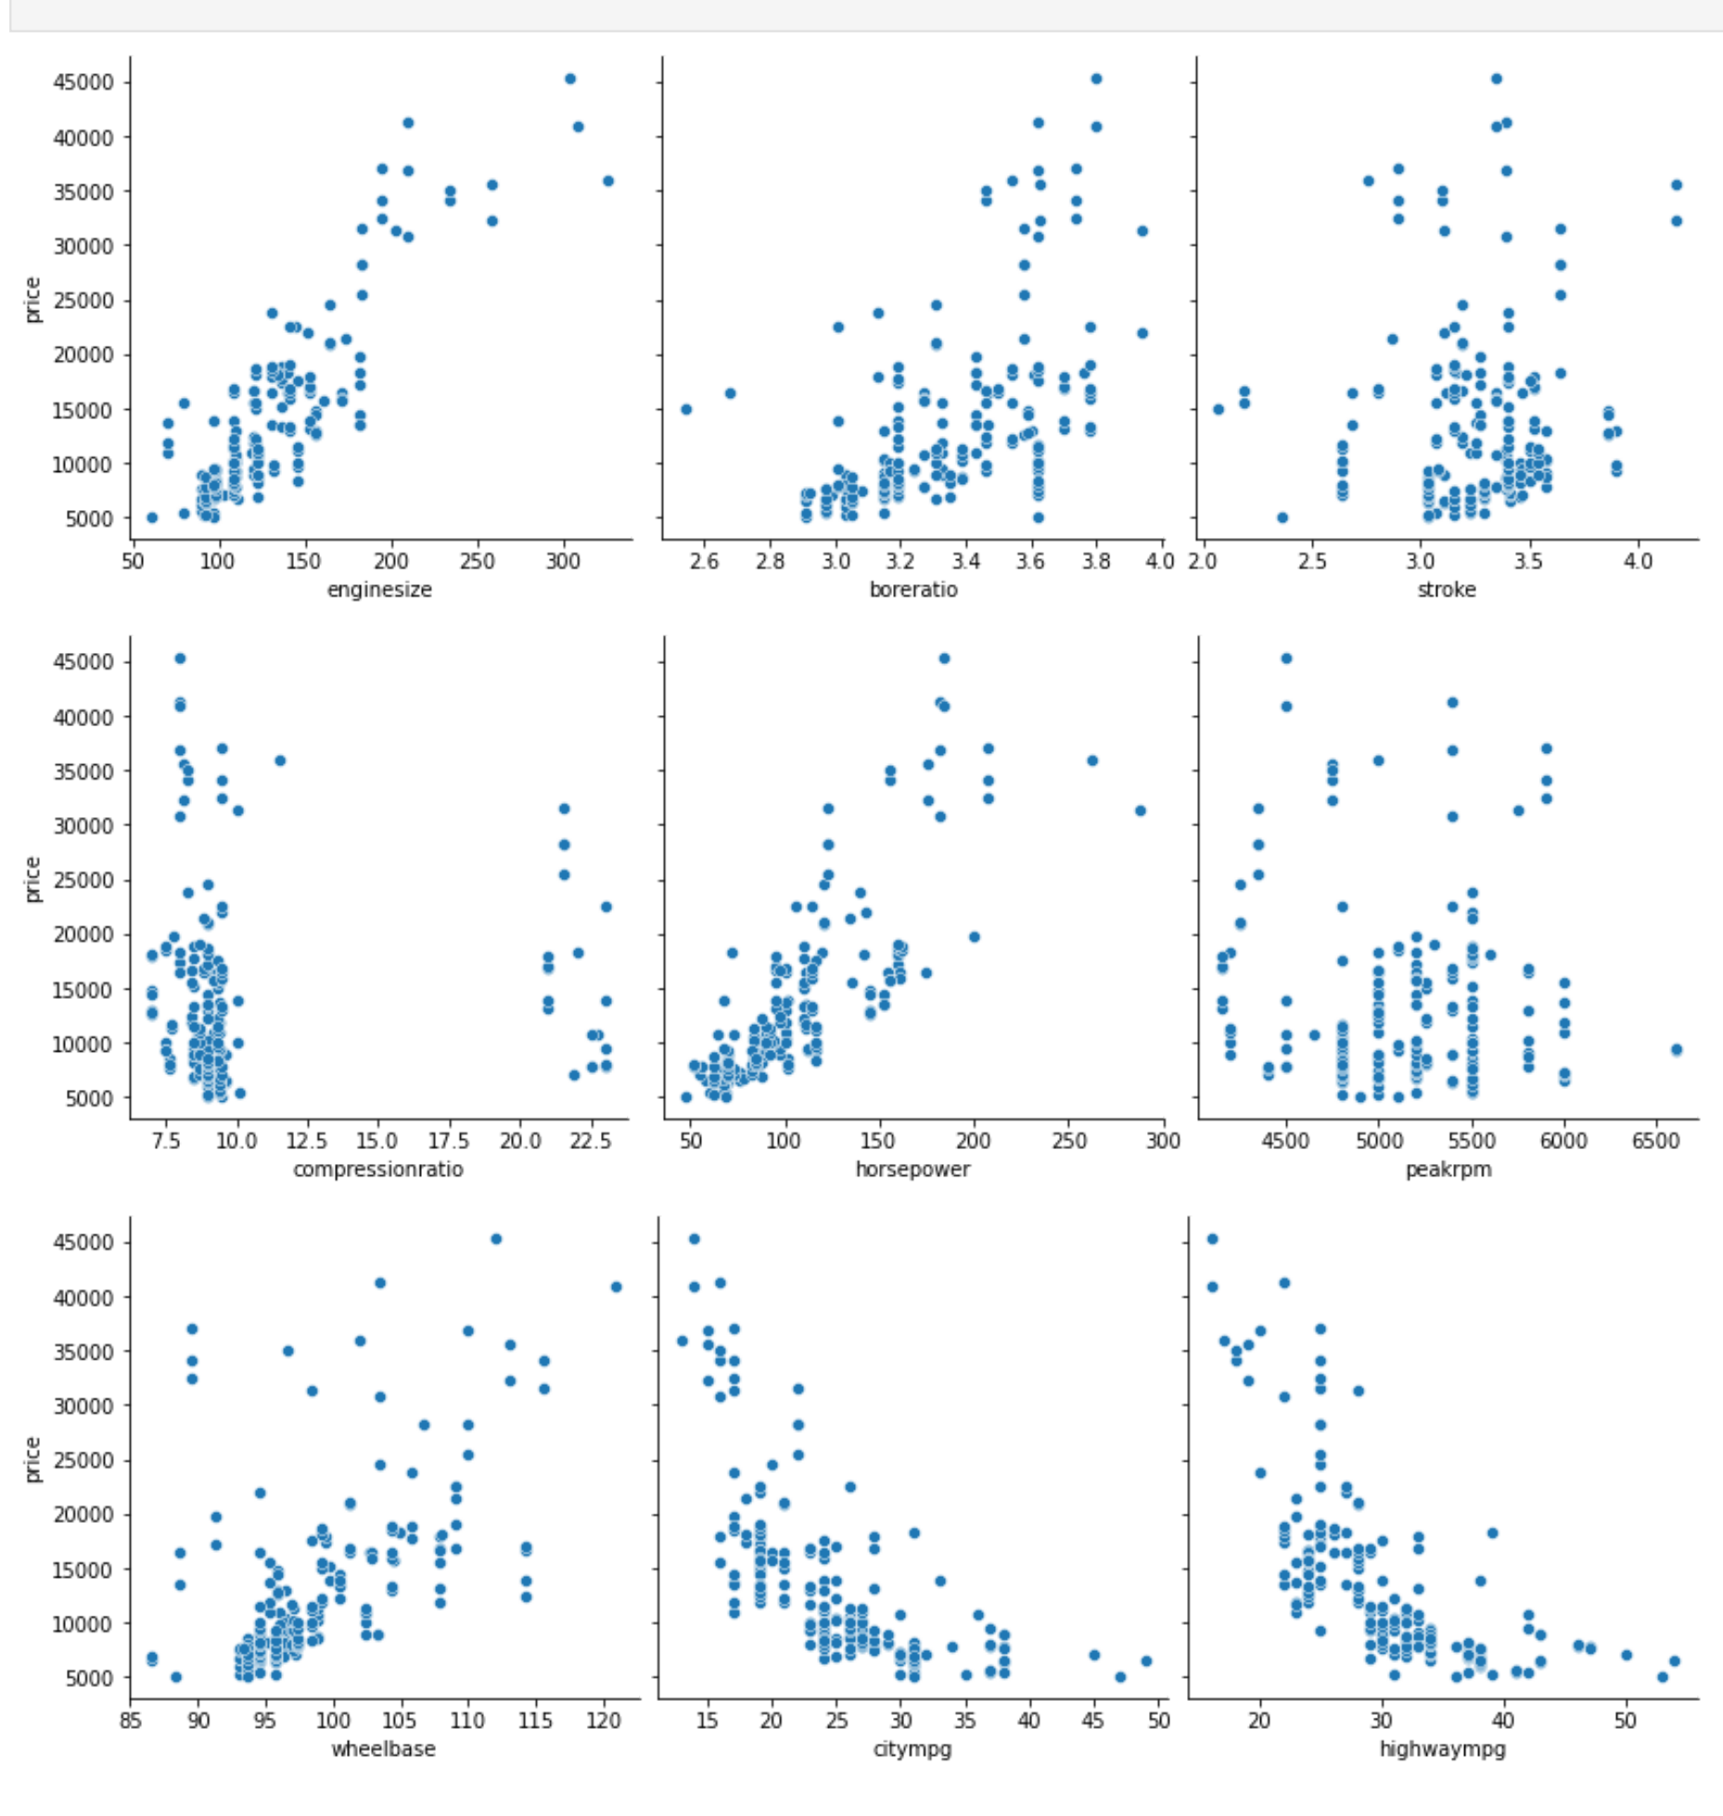

Latihan (5)

Buat Visualisasi Heatmap dari kolom:

'enginesize', 'boreratio', 'stroke','compressionratio', 'horsepower', 'peakrpm', 'wheelbase', 'citympg', 'highwaympg'

In [43]:
```
plt.figure(figsize = (8,8))
data_fitur = dataset[['enginesize', 'boreratio', 'stroke', 'compressionratio','horsepower', 'peakrpm', 'wheelba
sns.heatmap(data_fitur.corr(), annot=False, fmt="f").set_title("Korelasi Heatmap Calon Variabel X")
plt.show()
```

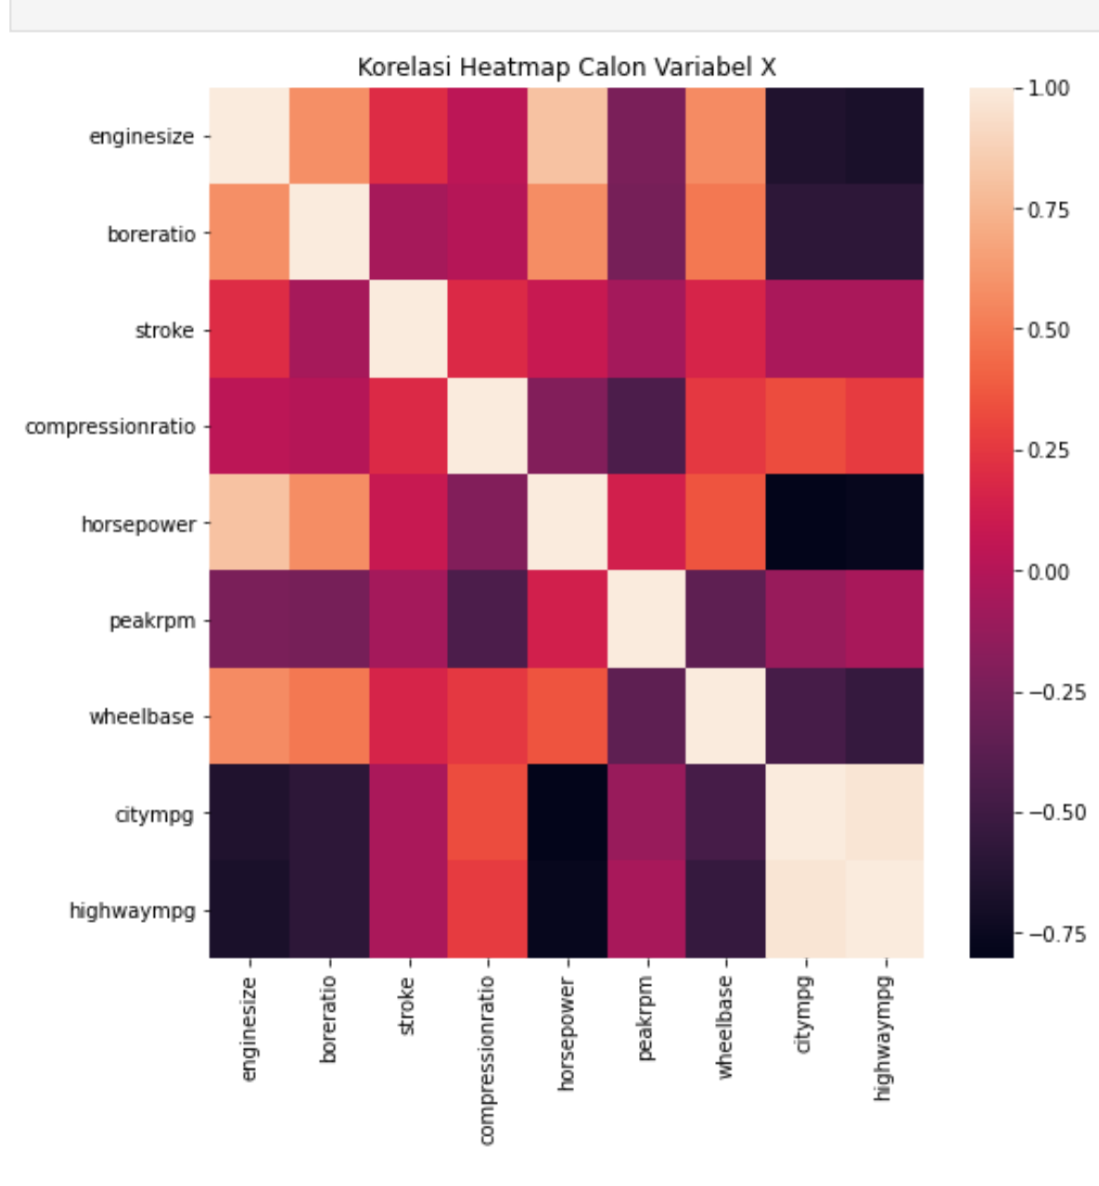

Dari hasil visualisasi diatas bahwa fitur/kolom enginesize memiliki korelasi yang tinggi terhadap kolom price / variabel dependent sehingga kita mengambil fitur/kolom enginesize untuk di training

- Independent variabel(x) adalah enginesize.
- Dependent variabel(y) adalah price.

Latihan (6)

Buat Visualisasi Scatter Plot antara calon variabel X(enginesize) dan y(price):

In [44]:
```
plt.scatter(dataset['enginesize'], dataset['price'])
plt.xlabel('enginesize')
plt.ylabel('price')
plt.title('Scatter Plot enginesize vs Price')
plt.show()
```

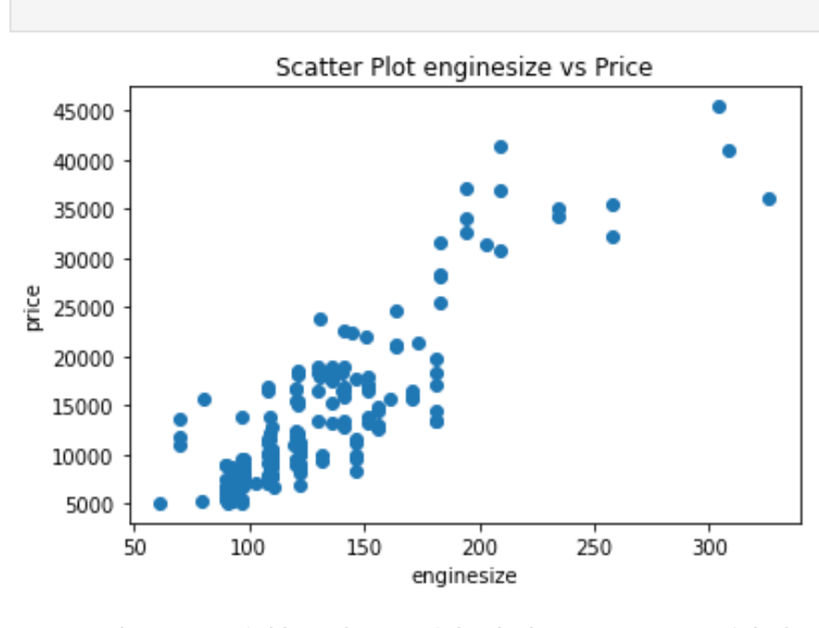

Scatter plot menunjukkan dengan jelas hubungan antarvariabel serta sebarannya di dataset. Selain itu, dengan scatter plot juga kita dapat mengindikasikan bahwa variabel enginesize dan price memiliki hubungan linear.

```
Catatan : korelasi 0.874145 adalah nilai yang cukup tinggi, artinya nilai price benar-benar sangat
dipengaruhi oleh nilai enginesize, karena korelasi tinggi maka algoritma Regresi Linier ini cocok
digunakan untuk data tersebut.
```

Latihan (7)

definisi variabel X(enginesize) dan y(price):

In [45]:
```
# Prepare data
# Pertama, buat variabel x dan y.
x = dataset['enginesize'].values.reshape(-1,1)
y = dataset['price'].values.reshape(-1,1)
```

Formula Regresi Linear

"Jika kita melihat formula regresi linear di atas, kita pasti ingat rumus persamaan garis yang pernah dipelajari di bangku sekolah, yaitu y = mx + c, dimana m merupakan gradien atau kemiringan garis dan c merupakan konstanta."

- from scratch
- y = ax + b atau y = w1x + w0 atau y = mx + c
- x = input
- y = output
- b atau w0 = intercept / bias
- a atau w1 = slope / gradient / coefficient

Latihan (8)

definisi variabel nilai mean/rata-rata X(enginesize) dan nilai mean/rata-rata y(price):

In [46]:
```
x_mean = np.mean(dataset['enginesize'])
y_mean = np.mean(dataset['price'])
print('nilai mean var x: ', x_mean,'\n'
      'nilai mean var y: ', y_mean)
```

```
nilai mean var x:  126.90731707317073
nilai mean var y:  13276.710570731706
```

Latihan (9)

carilah nilai koefisien korelasi nya dengan rumus dibawah:

In [47]:
```
atas = sum((x - x_mean)*(y - y_mean))
bawah = math.sqrt((sum((x - x_mean)**2)) * (sum((y - y_mean)**2)))
correlation = atas/bawah
print('Nilai Correlation Coefficient: ', correlation)
```

```
Nilai Correlation Coefficient:  [0.8741448]
```

carilah nilai parameter theta 1 dan theta 0 dengan rumus dibawah:

```
theta_1 = ((111-104.11) * (13495-13276.71)) + ... + ((114-104.11) * (22625-13276.71)) / ((111-104.11)^2
+ ... + (114-104.11)^2)
```

Latihan (10)

carilah nilai theta_1 atau nilai slope

In [48]:
```
# slope
# Slope adalah tingkat kemiringan garis, intercept
# adalah jarak titik y pada garis dari titik 0

variance = sum((x - x_mean)**2)
covariance = sum((x - x_mean) * (y - y_mean))
theta_1 = covariance/variance
print('Nilai theta_1: ', theta_1)
```

```
Nilai theta_1:  [167.69841639]
```

Latihan (11)

carilah nilai theta_0 atau nilai intercept

In [49]:
```
# intercept
theta_0 = y_mean - (theta_1 * x_mean)
print('Nilai theta_1: ', theta_0)
```

```
Nilai theta_1:  [-8005.44553115]
```

Maka persamaan garis :

y = 167.69x - 8005.44

Jadi persamaan garis diatas dapat digunakan untuk melakukan prediksi apabila kita memiliki data enginesize yang baru, price dapat diperkirakan dengan rumus tersebut, masukkan nilai enginesize baru ke x, maka perkiraan nilai y (price) akan didapat.

Latihan (12)

carilah nilai prediksi secara manual dan buatlah visualisasi scater plot nya

In [50]:
```
# prediction manual
y_pred = theta_0 + (theta_1 * 130)

print(y_pred)
```

```
[13795.34859997]
```

In [73]:
```
# visualisasi prediksi dengan scatter plot
y_pred = theta_0 + (theta_1 * x)

plt.scatter(dataset['enginesize'], dataset['price'])
plt.plot(x, y_pred, c='r')
plt.xlabel('enginesize')
plt.ylabel('Price')
plt.title('Plot enginesize vs Price')
plt.show()
```

Linier Regression digunakan untuk Prediksi dengan mencari pola garis terbaik antara variable independent dan dependen

Pros:

```
Mudah diimplementasikan
Digunakan untuk memprediksi nilai numerik/ continous /data jenis interval dan ratio
```

Cons :

```
Cenderung mudah Overfitting
Tidak dapat digunakan bila relasi antara variabel independen dan dependen tidak linier atau korelasi
variabel rendah
```

Linier Regression dengan menggunakan library sklearn

1. Pertama yang kita lakukan adalah split data, Train/test split adalah salah satu metode yang dapat digunakan untuk mengevaluasi performa model machine learning. Metode evaluasi model ini membagi dataset menjadi dua bagian yakni bagian yang digunakan untuk training data dan untuk testing data dengan proporsi tertentu. Train data digunakan untuk fit model machine learning, sedangkan test data digunakan untuk mengevaluasi hasil fit model tersebut.

Python memiliki library yang dapat mengimplementasikan train/test split dengan mudah yaitu Scikit-Learn. Untuk menggunakannya, kita perlu mengimport Scikit-Learn terlebih dahulu, kemudian setelah itu kita dapat menggunakan fungsi train_test_split().

Latihan (13)

split data train dan test dengan function train_test_split() dengan train_size=0.8, test_size=0.2 dan random_state=100

In [52]:
```
X_train, X_test, y_train, y_test = train_test_split(x, y, train_size=0.8, test_size=0.2, random_state=100)
```

- X_train: Untuk menampung data source yang akan dilatih.
- X_test: Untuk menampung data target yang akan dilatih.
- y_train: Untuk menampung data source yang akan digunakan untuk testing.
- y_test: Untuk menampung data target yang akan digunakan untuk testing.

X dan y adalah nama variabel yang digunakan saat mendefinisikan data source dan data target. Parameter *test_size* digunakan untuk mendefinisikan ukuran data testing. Dalam contoh di atas, test_size=0.2 berarti data yang digunakan sebagai data testing adalah sebesar 20% dari keseluruhan dataset.

Perlu diketahui bahwa metode ini akan membagi train set dan test set secara random atau acak. Jadi, jika kita mengulang proses running, maka tentunya hasil yang didapat akan berubah-ubah. Untuk mengatasinya, kita dapat menggunakan parameter *random_state*

Latihan (14)

buat object variabel linier regression

In [53]:
```
regressor = LinearRegression()
```

Latihan (15)

training the model menggunakan training data yang sudah displit sebelumnya.

In [54]:
```
regressor.fit(X_train, y_train)
```

Out[54]:
```
LinearRegression()
```

Latihan (16)

cari tau nilai slope/koefisien (m) dan intercept (b), dengan menggunakan function dari library sklearn -> LinierRegression

In [55]:
```
print(regressor.coef_)
print(regressor.intercept_)
```

```
[[168.17363122]]
[-8037.06049611]
```

Dari nilai m dan b diatas, kalau dimasukan ke dalam rumus persamaan menjadi:

y = 168.17x - 8037.06

Latihan (17)

cari tahu accuracy score dari model kita menggunakan testing data yang sudah displit sebelumnya. Dan nilai korelasinya

In [56]:
```
regressor.score(X_test, y_test)
```

Out[56]:
```
0.8068161903454086
```

Model kita mendapatkan accuracy score sebesar 80.68%

In [57]:
```
print('Correlation: ', math.sqrt(regressor.score(X_test, y_test)))
```

```
Correlation:  0.8982294753265496
```

Latihan (18)

visualisasi Regression Line menggunakan data testing.

In [85]:
```
y_prediksi = regressor.predict(X_test)

plt.scatter(X_test, y_test)
plt.plot(X_test, y_prediksi, c='r')
plt.xlabel('enginesize')
plt.ylabel('Price')
plt.title('Plot enginesize vs Price')
plt.show()
```

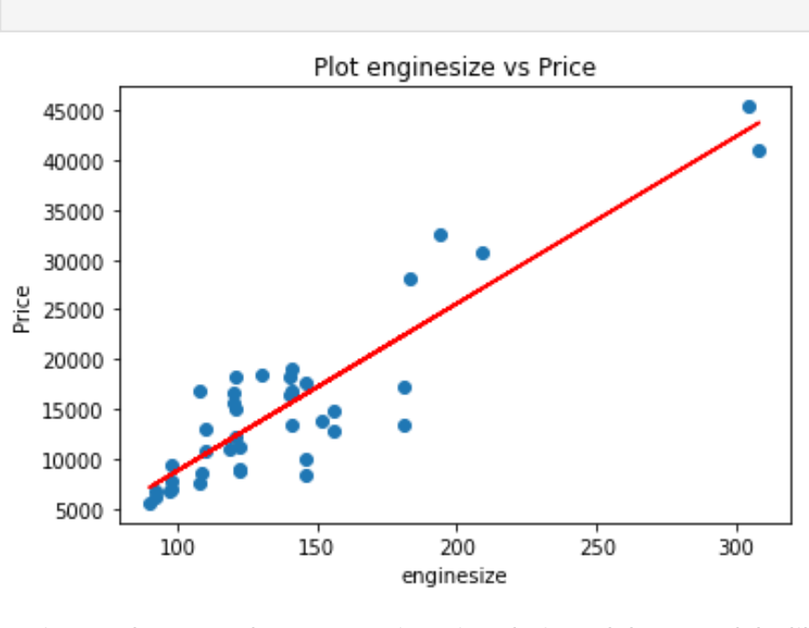

Garis merah merupakan Regression Line dari model yang telah dibuat sebelumnya.

Latihan (19)

Setelah kita yakin dengan model yang dibuat, selanjutnya adalah prediksi dari harga mobil dengan enginesize 100, 150, dan 200.

In [59]:
```
#Prediksi harga mobil dengan enginesize 130.

print('nilai prediksi harga dengan enginesize 100 : ', regressor.predict([[100]]))
print('nilai prediksi harga dengan enginesize 150 : ', regressor.predict([[150]]))
print('nilai prediksi harga dengan enginesize 200 : ', regressor.predict([[200]]))
```

```
nilai prediksi harga dengan enginesize 100 :  [[8780.30262568]]
nilai prediksi harga dengan enginesize 150 :  [[17188.98418658]]
nilai prediksi harga dengan enginesize 200 :  [[25597.66574748]]
```

In [60]:
```
np_table = np.concatenate((X_test, y_test, y_prediksi), axis=1)
new_dataframe = pd.DataFrame(data=np_table, columns=['x_test', 'y_test', 'y_predict'])
```

In [61]:
```
new_dataframe
```

Out[61]:

	x_test	y_test	y_predict
0	98.0	7738.0	8443.955363
1	109.0	8495.0	10293.865307
2	122.0	8845.0	12480.122512
3	98.0	9298.0	8443.955363
4	108.0	7603.0	10125.691675
5	122.0	11245.0	12480.122512
6	130.0	18420.0	13825.511562
7	140.0	16503.0	15507.247874
8	146.0	17669.0	16516.289662
9	181.0	17199.0	22402.366754
10	141.0	16845.0	15675.421506
11	121.0	18150.0	12311.948881
12	120.0	15580.0	12143.775250
13	110.0	12945.0	10462.038938
14	308.0	40960.0	43760.417919
15	92.0	6855.0	7434.913576
16	98.0	6938.0	8443.955363
17	121.0	12170.0	12311.948881
18	140.0	18280.0	15507.247874
19	156.0	14869.0	18198.025974
20	141.0	13415.0	15675.421506
21	141.0	16515.0	15675.421506
22	194.0	32528.0	24588.623960
23	90.0	5572.0	7098.566314
24	146.0	8449.0	16516.289662
25	181.0	13499.0	22402.366754
26	156.0	12764.0	18198.025974
27	183.0	28176.0	22738.714017
28	108.0	16925.0	10125.691675
29	119.0	11048.0	11975.601619
30	92.0	6189.0	7434.913576
31	209.0	30760.0	27111.228428
32	152.0	13860.0	17525.331449
33	141.0	19045.0	15675.421506
34	120.0	16630.0	12143.775250
35	110.0	10698.0	10462.038938
36	121.0	15040.0	12311.948881
37	146.0	9989.0	16516.289662
38	97.0	6849.0	8275.781732
39	122.0	8948.0	12480.122512
40	304.0	45400.0	43087.723394

Semakin tinggi nilai error, semakin besar errornya

Latihan (20)

Cetak nilai Mean Absolute Error, Mean Squared Error, dan Root Mean Squared Error

In [62]:
```
from sklearn import metrics

print('Mean Absolute Error:', metrics.mean_absolute_error(y_test, y_prediksi))
print('Mean Squared Error:', metrics.mean_squared_error(y_test, y_prediksi))
print('Root Mean Squared Error:', np.sqrt(metrics.mean_squared_error(y_test, y_prediksi)))
```

```
Mean Absolute Error: 3123.611515387693
Mean Squared Error: 14882644.972928163
Root Mean Squared Error: 3857.8031278083854
```

In [63]:
```
plt.title('Comparison of Y values in test and the Predicted values')
plt.ylabel('Test Set')
plt.xlabel('Predicted values')
plt.plot(y_prediksi, '.', y_test, 'x')
plt.show()
```